

# Compiladores - Análise Léxica

Alisson da S. Vieira

<sup>1</sup>Ciência da Computação – Universidade Tecnológica Federal do Paraná (UTFPR)  
Caixa Postal 15.064 – 91.501-970 – Campo Mourão – PR – Brasil

`alissonv@alunos.utfpr.edu.br`

**Abstract.** *For this work, a start code for Lexical Analysis was provided by the teacher. The Analysis is the first step of the compilation process, where the language tokens are extracted. The language chosen was T++, and the work describes a little about the characteristics of the language. It also discusses which language and library was used to perform the analysis, as well as showing output examples at the end.*

**Resumo.** *Para este trabalho, foi disponibilizado pelo professor, um código inicial para a Análise Léxica. Esta que é a primeira etapa do processo de compilação, onde basicamente se extrai os tokens da linguagem. A linguagem escolhida foi o T++, e o trabalho descreve um pouco sobre as características da linguagem. Ele também aborda sobre qual linguagem e biblioteca foi utilizada para realizar a análise, além de ao final mostrar exemplos de saída.*

## 1. Introdução

A análise léxica, é um processo de compilação que, faz uma varredura no código fonte, com o objetivo de converter os caracteres presentes no código em um conjunto de marcas (tokens). Esses tokens representam caracteres do código, como: laços de repetições (for, while, foreach, etc), comparações (if, else, etc), símbolos especiais (+, -, \*, /, etc). A saída desse processo de análise léxica é uma lista desses tokens, que serão utilizados nas próximas etapas do processo de compilação.

## 2. Objetivo

Estaremos realizando na disciplina um compilador para a linguagem de programação fictícia T++, esta que foi desenvolvida com o intuito de auxiliar com o aprendizado dos alunos na disciplina. Neste trabalho especificamente, estaremos realizando a análise léxica a primeira parte do processo de compilação, e para trabalho foi utilizado a linguagem de programação python com a biblioteca Ply. A decisão de se utilizar python, se deve ao fato de que é uma linguagem voltada para a produtividade, possuindo diversas ferramentas nativas que auxiliam o desenvolvedor a apenas focar em produzir. Já a escolha de usar a biblioteca Ply, se deve ao fato de que ela fornece a maioria dos recursos lex/yacc padrões, incluindo suporte para: produções vazias, regras de precedência, recuperação de erros e suporte para gramáticas ambíguas, além de ser relativamente simples de se usar.

## 3. Linguagem de Programação T++

A linguagem T++, como já foi dito anteriormente, foi desenvolvida para auxiliar no processo de aprendizagem dos alunos, e ela é totalmente em português. Quanto aos tipos

básicos suportados pela linguagem são tipos inteiro e flutuante, além de contar com suporte a arranjos unidimensionais e bidimensionais. Nessa linguagem quando o retorno de uma função é omitido ela automaticamente vira um procedimento, caso contrário vira uma função. Nas subseções abaixo iremos ver mais detalhes sobre as características dessa linguagem.

### 3.1. Tipos de variáveis

Os tipos de variáveis suportadas pela linguagem são:

- Números inteiros
- Números reais
- Números com notação científica

### 3.2. Operações

Os tipos de operações suportadas pela linguagem são:

<i><b>OPERAÇÃO</b></i>	<i><b>SÍMBOLO</b></i>
<b>Soma</b>	+
<b>Subtração</b>	-
<b>Multiplicação</b>	*
<b>Divisão</b>	/
<b>OR</b>	
<b>AND</b>	&&
<b>NOT</b>	!

Tabela 1. Operações suportadas na linguagem T++.

### 3.3. Comparações

Os tipos de comparações suportadas pela linguagem são:

<i><b>OPERAÇÃO</b></i>	<i><b>SÍMBOLO</b></i>
<b>Maior</b>	>
<b>Menor</b>	<
<b>Maior igual</b>	>=
<b>Menor igual</b>	<=
<b>Diferença</b>	<>

Tabela 2. Comparações suportadas pela linguagem T++.

### 3.4. Palavras reservadas

As palavras reservadas pela linguagem são:

- se
- então
- senão
- fim

- repita
- flutuante
- retorna
- ate
- escreva
- inteiro

### 3.5. Exemplo de código

Na Figura 1 temos um exemplo de um código em T++. Este código é um teste simples que utiliza quase tudo que foi discutido nas seções: variáveis, tipo de função, laço de repetição, comparação, igualdade, etc.

```
inteiro principal()  
  inteiro: a  
  
  a := 1  
  
  repita  
  |  
  | se a = 10  
  | | escreva(a)  
  | fim  
  |  
  | a := a + 1  
  |  
  ate a = 10  
  
  retorna(0)  
fim
```

Figura 1. Código em T++.

Nesse exemplo, temos apenas uma função, a função principal que retorna um valor inteiro. De início declaramos uma variável de nome *a* do tipo inteiro, e setamos o valor de 1 a ela. Logo após, temos um loop, que se repete até que essa variável *a* seja igual ao valor 10. Dentro desse loop fazemos apenas uma verificação simples, verificamos se o valor de *a* é 10, caso positivo escrevemos esse valor com a função “escreva”, caso não seja 10, aumentamos em 1 no valor da variável *a*. E ao final do código, retornamos 0.

## 4. Expressões Regulares

Como foi dito anteriormente, a análise léxica faz uma varredura no código fonte, com o objetivo de identificar tokens. Para realizar esse processo de identificação, foi utilizado expressões regulares para cada um dos símbolos, tanto simples quanto complexos. Um expressão regular é uma técnica que provê uma forma concisa e flexível de identificar cadeias de caracteres específicas. A tabela 3 mostra as expressões simples que foram usadas para identificação de alguns tokens, e a tabela 4 mostra as expressões complexas que foram usadas para identificar os tokens restantes.

<i>OPERAÇÃO</i>	<i>SÍMBOLO</i>
<b>Adição</b>	\ +
<b>Subtração</b>	-
<b>Multiplicação</b>	\ *
<b>Divisão</b>	\ /
<b>Abre parenteses</b>	\ (
<b>Fecha parenteses</b>	\ )
<b>Abre colchete</b>	[
<b>Fecha colchete</b>	]
<b>Virgula</b>	,
<b>Atribuição</b>	:=
<b>Dois pontos</b>	:
<b>E lógico</b>	&&
<b>OU lógico</b>	\ — \ —
<b>Negação</b>	!
<b>Diferença</b>	< >
<b>Menor igual</b>	< =
<b>Maior igual</b>	> =
<b>Menor</b>	<
<b>Maior</b>	>
<b>Igual</b>	=

Tabela 3. Expressões regulares simples

<i>TOKEN</i>	<i>EXPRESSÃO REGULAR</i>
<b>Dígito</b>	$([0-9])$
<b>Letra</b>	$([a-zA-Z\tilde{A}\tilde{a}\tilde{\AA}\tilde{\text{À}}\tilde{\text{É}}\tilde{\text{Í}}\tilde{\text{Ó}}\tilde{\text{Õ}}])$
<b>Sinal</b>	$([\backslash - \backslash +]?)$
<b>ID</b>	$(([a-zA-Z\tilde{A}\tilde{a}\tilde{\AA}\tilde{\text{À}}\tilde{\text{É}}\tilde{\text{Í}}\tilde{\text{Ó}}\tilde{\text{Õ}}])(( [0-9] )+   \_   ([a-zA-Z\tilde{A}\tilde{a}\tilde{\AA}\tilde{\text{À}}\tilde{\text{É}}\tilde{\text{Í}}\tilde{\text{Ó}}\tilde{\text{Õ}}]))*)$
<b>Inteiro</b>	$\backslash d+$
<b>Flutuante</b>	$\backslash d+[eE][\backslash -+]? \backslash d+   (\backslash . \backslash d+   nd + n.nd*) ([eE][\backslash -+]? \backslash d+)?$
<b>Notação Científica</b>	$([\backslash -+]?)([1-9])\backslash .([0-9])+ [eE]( [\backslash -+]? )([0-9]+)$
<b>Comentário</b>	$(\{((\backslash — \backslash n)^*)?\})$
<b>Nova linha</b>	$\backslash n+$

Tabela 4. Expressões regulares complexas.

## 5. Autômatos

Uma expressão regular define formalmente um padrão, mostrando quais os sub-padrões ou expressões regulares que a formam, com qual regularidade ou sequencia cada uma

delas aparece, e quais são os diferentes sub-padrões que podem ser reconhecidos em uma mesma posição do padrão. Vamos pegar por exemplo a expressão 1, onde o “a” representa o carácter, o “\*” significa que a sequência de caracteres “[0-9]” (quais quer números de 0 a 9) podem se repetir.

$$(a * [0 - 9]) \quad (1)$$

Dado a seguinte sequência de caracteres: “a a1 a09 a123”, os caracteres retornados após a aplicação dessa expressão regular seria: “a1”, “a09” e “a123”. Qualquer expressão regular pode ser convertida em um autômato finito que ela descreve, e vice versa, ou seja, podemos converter a expressão 1 em um automato finito, como vemos na Figura 2.




Figura 2. Autômato resultante da conversão da expressão 1.

Assim como fizemos com a expressão 1, podemos fazer o mesmo com todas as expressões regulares já mostradas acima, e para exemplificar iremos usar a expressão 2 que identifica o token DIGITO.

$$([0 - 9]) \quad (2)$$

Para essa expressão, o automato resultante da conversão é o representado na Figura 3.




Figura 3. Autômato resultante da conversão da expressão 2.

Também podemos observar na Figura 4, um automato para identificar a palavra reservada “repita”.



Figura 4. Autômato que identifica a palavra reservada “repita”.

## 6. Detalhes de implementação

Como já foi citado anteriormente, para realizar esse trabalho foi disponibilizado pelo professor um código inicial, utilizando a linguagem de programação Python, e a biblioteca Ply (Python Lex-Yacc). O ply conta com 2 módulos separados: lex.py e yacc.py, para a análise léxica iremos estar utilizando o lex.py. O lex.py já prove uma implementação para pegar os tokens de um dado arquivo, como pode ser observado na Figura 5. Para utilizar essa função, é necessário antes construir a instância do lexer, e passar o arquivo para ele realizar a leitura.

```

# construir a instancia do lexer
lexer = lex.lex(optimize=True, debug=True, debuglog=log)
lexer.input(source_file)

while True:

    # pegar os tokens
    tok = lexer.token()

    # No more input
    if not tok:
        break
  
```

Figura 5. Construção da instancia do lex, e função que pega os tokens.

E dessa forma, para todos os tokens que definimos, podemos criar funções que irão se executar assim que o lex encontrar o token referenciado, como mostra a Figura 6. No caso dessa função, toda vez que o lex identificar o token da notação científica (expressão regular identificada na tabela 4) ele irá apenas retornar o token, que é justamente o que queremos. Na Figura 6 como já foi dito, apenas retornamos o token, porém, temos casos como o da Figura 7 em que temos que realizar um tratamento, nesse caso, temos que pular as linhas.

```

@TOKEN(notacao_cientifica)
def t_NUM_NOTACAO_CIENTIFICA(token):

    return token
  
```

Figura 6. Exemplo função lex.

```

@TOKEN(nova_linha)
def t_NEWLINE(token):

    # para pular as linhas referentes ao valor
    token.lexer.lineno += len(token.value)

    # não a necessidade de retornar o token
  
```

Figura 7. Exemplo função nova linha do lex .

Foram feitas algumas melhorias em relação a saída do programa, foi implementado um argumento adicional 'd', onde na hora de execução do programa conseguimos observar uma saída mais detalhada da execução como vemos na Figura 8, além de uma mensagem de erro mais detalhada também como mostra a Figura 9.

```
if detailed:
    print(tok)
    arq.write(str(tok) + '\n')
else:
    print(tok.type)
    arq.write(str(tok.type) + '\n')
```

Figura 8. Saída mais detalhada.

```
# tratamento de erros
def t_error(token):

    # variáveis para controle
    global error, detailed

    error = True

    if detailed:
        print(
            'Foi encontrado um caracter inválido: "{}", na linha: {} e na coluna {}'.format(token.value, token.lineno, token.lexpos)
        )
    else:
        print("Caracter inválido '{}'.format(token.value[0]))

    # pulo o erro
    token.lexer.skip(1)
```

Figura 9. Função erro, com adição de uma saída mais detalhada.

Juntamente com o argumento adicional, também foi feito uma melhoria da saída da execução do código, onde toda vez que o mesmo for executado, seu resultado estará disponível em um arquivo chamado “saida.txt” na pasta do programa.

## 7. Execução do código

Para testar nosso código, foi usado como código de entrada, um exemplo em T++ que implementa o algoritmo de busca linear, como mostra a Figura 10.

```

inteiro: A[20]

inteiro busca(inteiro: e)
    inteiro: retorno
    inteiro: i

    retorno := 0
    i := 0

    repita
        se A[i] = e
            retorno := 1
        fim
        i := i + 1
    até i = 20

    retorna(retorno)
fim

inteiro principal()
    inteiro: e
    inteiro: i

    i := 0

    repita
        A[i] := i
        i := i + 1
    até i = 20

    leia(e)
    escreva(busca(e))
    retorno(0)
fim

```

Figura 10. Código de exemplo em T++.

E para esse exemplo, temos a saída completa sem o parâmetro “d” na hora da execução na Figura 11, e a saída com o parâmetro “d” na Figura 12

1	INTEIRO	36	NUM_INTEIRO	71	ID
2	DOIS_PONTOS	37	FIM	72	ID
3	ID	38	ID	73	ATRIBUICAO
4	ABRE_COLCHETE	39	ATRIBUICAO	74	ID
5	NUM_INTEIRO	40	ID	75	MAIS
6	FECHA_COLCHETE	41	MAIS	76	NUM_INTEIRO
7	INTEIRO	42	NUM_INTEIRO	77	ATE
8	ID	43	ATE	78	ID
9	ABRE_PARENTESE	44	ID	79	IGUAL
10	INTEIRO	45	IGUAL	80	NUM_INTEIRO
11	DOIS_PONTOS	46	NUM_INTEIRO	81	LEIA
12	ID	47	RETORNA	82	ABRE_PARENTESE
13	FECHA_PARENTESE	48	ABRE_PARENTESE	83	ID
14	INTEIRO	49	ID	84	FECHA_PARENTESE
15	DOIS_PONTOS	50	FECHA_PARENTESE	85	ESCREVA
16	ID	51	FIM	86	ABRE_PARENTESE
17	INTEIRO	52	INTEIRO	87	ID
18	DOIS_PONTOS	53	ID	88	ABRE_PARENTESE
19	ID	54	ABRE_PARENTESE	89	ID
20	ID	55	FECHA_PARENTESE	90	FECHA_PARENTESE
21	ATRIBUICAO	56	INTEIRO	91	FECHA_PARENTESE
22	NUM_INTEIRO	57	DOIS_PONTOS	92	ID
23	ID	58	ID	93	ABRE_PARENTESE
24	ATRIBUICAO	59	INTEIRO	94	NUM_INTEIRO
25	NUM_INTEIRO	60	DOIS_PONTOS	95	FECHA_PARENTESE
26	REPITA	61	ID	96	FIM
27	SE	62	ID		
28	ID	63	ATRIBUICAO		
29	ABRE_COLCHETE	64	NUM_INTEIRO		
30	ID	65	REPITA		
31	FECHA_COLCHETE	66	ID		
32	IGUAL	67	ABRE_COLCHETE		
33	ID	68	ID		
34	ID	69	FECHA_COLCHETE		
35	ATRIBUICAO	70	ATRIBUICAO		

Figura 11. Saída da execução da análise léxica.



1	LexToken(INTEIRO, 'inteiro', 2, 1)	36	LexToken(NUM_INTEIRO, '1', 14, 136)	71	LexToken(ID, 'i', 29, 268)
2	LexToken(DOIS_PONTOS, ':', 2, 8)	37	LexToken(FIM, 'fim', 15, 148)	72	LexToken(ID, 'i', 30, 272)
3	LexToken(ID, 'A', 2, 10)	38	LexToken(ID, 'i', 16, 148)	73	LexToken(ATRIBUICAO, ':-', 30, 274)
4	LexToken(ABRE_COLCHETE, '[', 2, 11)	39	LexToken(ATRIBUICAO, ':-', 16, 150)	74	LexToken(ID, 'i', 30, 277)
5	LexToken(NUM_INTEIRO, '20', 2, 12)	40	LexToken(ID, 'i', 16, 153)	75	LexToken(MAIS, '+', 30, 279)
6	LexToken(FECHA_COLCHETE, ']', 2, 14)	41	LexToken(MAIS, '+', 16, 155)	76	LexToken(NUM_INTEIRO, '1', 30, 281)
7	LexToken(INTEIRO, 'inteiro', 4, 17)	42	LexToken(NUM_INTEIRO, '1', 16, 157)	77	LexToken(ATE, 'até', 31, 284)
8	LexToken(ID, 'busca', 4, 25)	43	LexToken(ATE, 'até', 17, 168)	78	LexToken(ID, 'i', 31, 288)
9	LexToken(ABRE_PARENTESE, '(', 4, 38)	44	LexToken(ID, 'i', 17, 164)	79	LexToken(IGUAL, '=', 23, 298)
10	LexToken(INTEIRO, 'inteiro', 4, 31)	45	LexToken(IGUAL, '=', 17, 166)	80	LexToken(NUM_INTEIRO, '20', 31, 292)
11	LexToken(DOIS_PONTOS, ':', 4, 38)	46	LexToken(NUM_INTEIRO, '20', 17, 168)	81	LexToken(LEIA, 'leia', 33, 297)
12	LexToken(ID, 'e', 4, 40)	47	LexToken(RETORNA, 'retorna', 19, 173)	82	LexToken(ABRE_PARENTESE, '(', 33, 301)
13	LexToken(FECHA_PARENTESE, ')', 4, 41)	48	LexToken(ABRE_PARENTESE, '(', 19, 188)	83	LexToken(ID, 'e', 33, 302)
14	LexToken(INTEIRO, 'inteiro', 6, 46)	49	LexToken(ID, 'retorno', 19, 181)	84	LexToken(FECHA_PARENTESE, ')', 33, 303)
15	LexToken(DOIS_PONTOS, ':', 6, 53)	50	LexToken(FECHA_PARENTESE, ')', 19, 188)	85	LexToken(ESCREVA, 'escreva', 34, 306)
16	LexToken(ID, 'retorno', 6, 55)	51	LexToken(FIM, 'fim', 20, 190)	86	LexToken(ABRE_PARENTESE, '(', 34, 313)
17	LexToken(INTEIRO, 'inteiro', 7, 64)	52	LexToken(INTEIRO, 'inteiro', 22, 195)	87	LexToken(ID, 'busca', 34, 314)
18	LexToken(DOIS_PONTOS, ':', 7, 71)	53	LexToken(ID, 'principal', 22, 203)	88	LexToken(ABRE_PARENTESE, '(', 34, 319)
19	LexToken(ID, 'i', 7, 73)	54	LexToken(ABRE_PARENTESE, '(', 22, 212)	89	LexToken(ID, 'o', 34, 320)
20	LexToken(ID, 'retorno', 9, 77)	55	LexToken(FECHA_PARENTESE, ')', 22, 213)	90	LexToken(FECHA_PARENTESE, ')', 34, 321)
21	LexToken(ATRIBUICAO, ':-', 9, 85)	56	LexToken(INTEIRO, 'inteiro', 23, 216)	91	LexToken(FECHA_PARENTESE, ')', 34, 322)
22	LexToken(NUM_INTEIRO, '0', 9, 88)	57	LexToken(DOIS_PONTOS, ':', 23, 223)	92	LexToken(ID, 'retorno', 35, 325)
23	LexToken(ID, 'i', 10, 91)	58	LexToken(ID, 'e', 23, 225)	93	LexToken(ABRE_PARENTESE, '(', 35, 332)
24	LexToken(ATRIBUICAO, ':-', 10, 93)	59	LexToken(INTEIRO, 'inteiro', 24, 228)	94	LexToken(NUM_INTEIRO, '0', 35, 333)
25	LexToken(NUM_INTEIRO, '0', 10, 96)	60	LexToken(DOIS_PONTOS, ':', 24, 235)	95	LexToken(FECHA_PARENTESE, ')', 35, 334)
26	LexToken(REPITA, 'repita', 12, 100)	61	LexToken(ID, 'i', 24, 237)	96	LexToken(FIM, 'fim', 36, 336)
27	LexToken(SE, 'se', 13, 110)	62	LexToken(ID, 'i', 26, 241)		
28	LexToken(ID, 'A', 13, 113)	63	LexToken(ATRIBUICAO, ':-', 26, 243)		
29	LexToken(ABRE_COLCHETE, '[', 13, 114)	64	LexToken(NUM_INTEIRO, '0', 26, 246)		
30	LexToken(ID, 'i', 13, 115)	65	LexToken(REPITA, 'repita', 28, 250)		
31	LexToken(FECHA_COLCHETE, ']', 13, 116)	66	LexToken(ID, 'A', 29, 260)		
32	LexToken(IGUAL, '=', 13, 118)	67	LexToken(ABRE_COLCHETE, '[', 29, 261)		
33	LexToken(ID, 'e', 13, 120)	68	LexToken(ID, 'i', 29, 262)		
34	LexToken(ID, 'retorno', 14, 125)	69	LexToken(FECHA_COLCHETE, ']', 29, 263)		
35	LexToken(ATRIBUICAO, ':-', 14, 133)	70	LexToken(ATRIBUICAO, ':-', 29, 265)		

Figura 12. Saída detalhada da execução da análise léxica.

## References

Beazley, D. M. Documentação ply.py. <https://www.dabeaz.com/ply/ply.tml>.

Gonçalves, R. A. Conjunto de testes. <https://moodle.utfpr.edu.br/mod/resource/view.php?id=725874>.

Gonçalves, R. A. Slides - análise léxica. [https://moodle.utfpr.edu.br/pluginfile.php/239681/mod\\_resource/content/4/aula-05-analise-lexica-lex-ply.md.slides.pdf](https://moodle.utfpr.edu.br/pluginfile.php/239681/mod_resource/content/4/aula-05-analise-lexica-lex-ply.md.slides.pdf).